# Consultas en Hive - Laboratorio 3-2

# **Objetivo**

El objetivo de este laboratorio fue realizar consultas SQL en un dataset almacenado en HDFS utilizando Hive a través de la interfaz de Hue. Adicionalmente, se utilizó SparkSQL en JupyterHub para realizar consultas sobre el mismo dataset.

## **Instrucciones Paso a Paso**

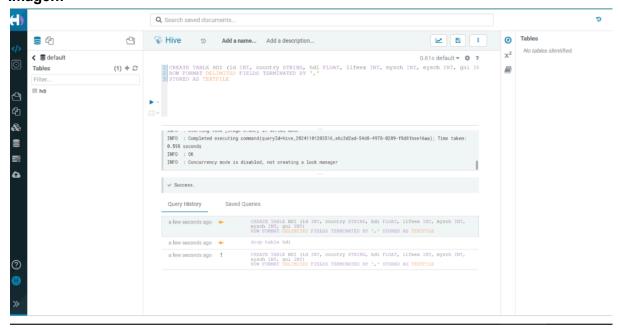
## 1. Acceso a Hue y Selección de Hive

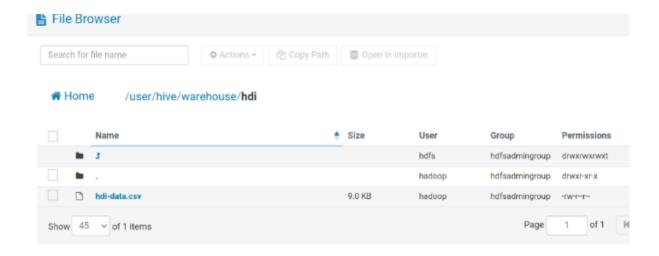
Primero, accedimos a la interfaz de Hue en el cluster EMR de AWS. Una vez en Hue, seleccionamos la opción de Hive para ejecutar consultas SQL sobre el dataset previamente cargado en HDFS.

### 2. Consulta SQL Básica en Hive

En Hue, ejecutamos una serie de consultas SQL para explorar el contenido del dataset. Estas consultas incluyeron operaciones básicas como selección y filtrado de datos para obtener una visión general del contenido.

#### Imagen:

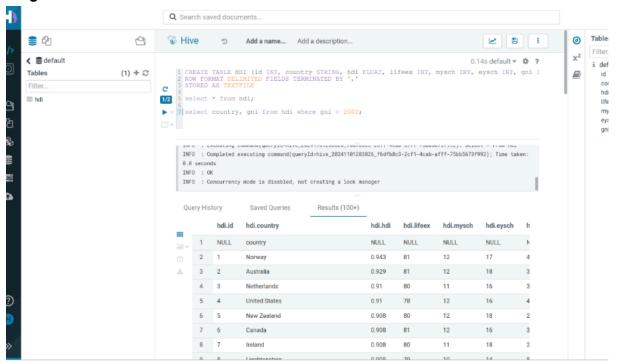


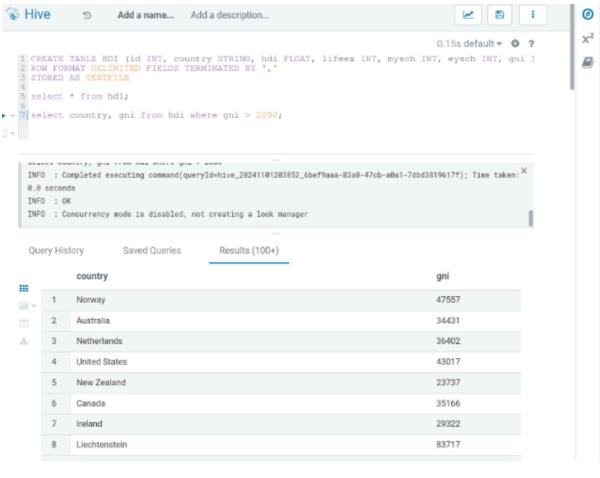


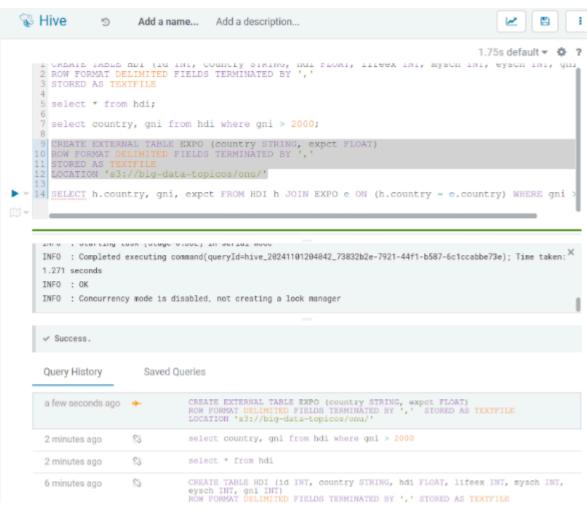
#### 3. Verificación de Resultados en Hue

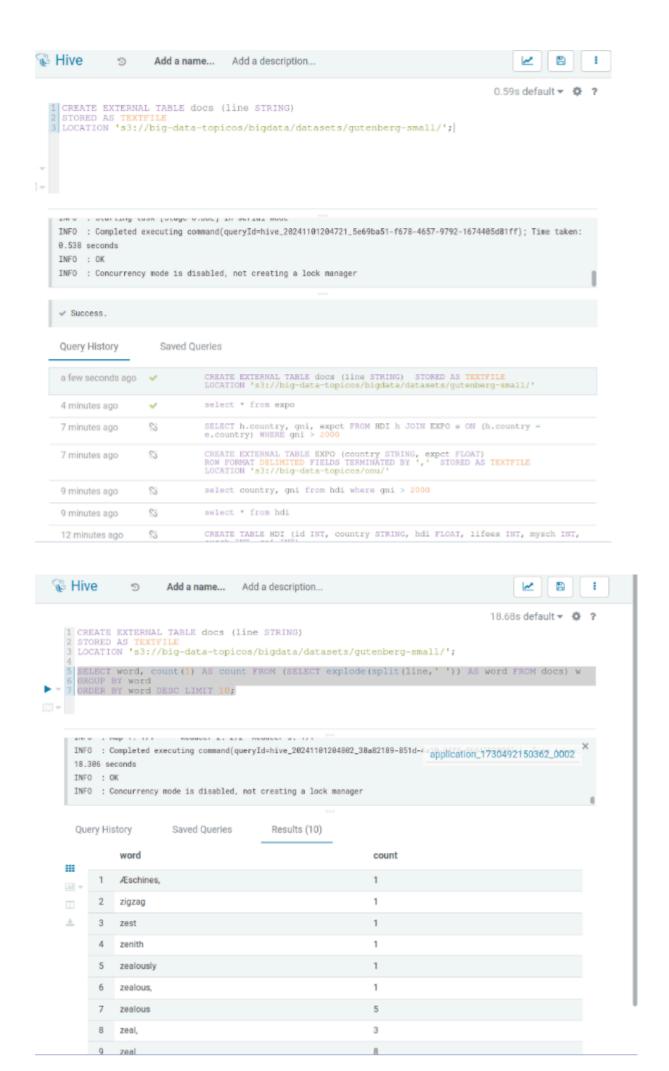
Luego de ejecutar las consultas, revisamos los resultados generados en Hive para asegurar que los datos del dataset fueran correctos y que las consultas se ejecutaran sin errores.

#### Imagen:





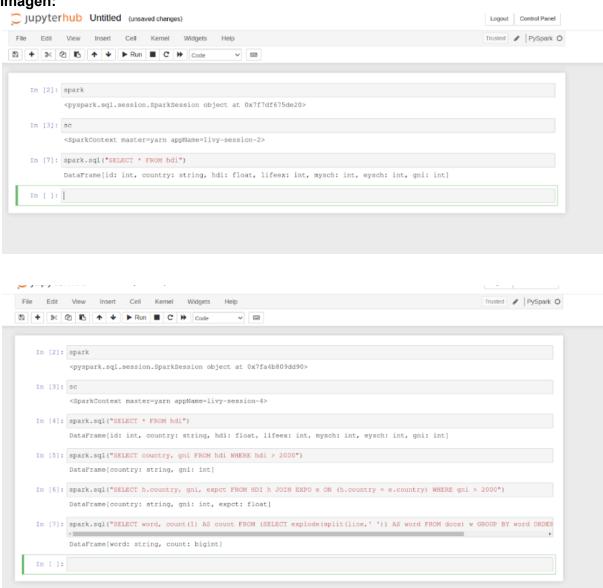




### 4. Consultas en JupyterHub usando SparkSQL

Además de usar Hive en Hue, se realizaron consultas sobre el mismo dataset en JupyterHub usando SparkSQL. Esto permitió comparar el rendimiento y facilidad de uso de SparkSQL frente a Hive para la misma tarea.





# Conclusión

Este laboratorio permitió explorar el uso de Hive en la interfaz de Hue para consultas SQL sobre datos en HDFS, así como el uso de SparkSQL en JupyterHub para realizar las mismas consultas. La práctica brindó experiencia en la manipulación de grandes volúmenes de datos y en la comparación de herramientas de consulta en el entorno Hadoop.